

Spark 基础知识

RDD、算子、进程模型、调度、Shuffle、内存与存储

来源：极客时间《零基础入门 Spark》。本文为学习笔记和工程化复盘，不包含课程逐字稿。

RDD 与延迟计算

- 1 RDD 是弹性分布式数据集，是 Spark 对分布式数据的基础抽象。
- 2 转换算子不会立即执行，行动算子才会触发作业提交。
- 3 RDD 之间的血缘关系让 Spark 可以在分区丢失后重新计算。

算子与 Shuffle

- 1 map、flatMap、filter 多数是窄依赖，reduceByKey、join、repartition 常常涉及 Shuffle。
- 2 Shuffle 会带来网络传输、磁盘读写和内存压力，是性能瓶颈高发区。
- 3 优化思路是提前过滤、减少无用列、控制分区数、处理倾斜和合理缓存。

执行模型

- 1 Driver 负责应用主控和 DAG 规划，Executor 负责执行 Task。
- 2 Stage 通常被 Shuffle 依赖切分，Task 是最小执行单元。
- 3 Partition 决定并行度粒度，太少会并行不足，太多会增加调度开销。

内存、变量与存储

- 1 执行内存服务 Join、Sort、Aggregation 和 Shuffle，存储内存服务 Cache、Persist 和广播变量。
- 2 广播变量适合分发小表和只读配置，累加器适合做分布式指标统计。
- 3 Spark 通常连接 HDFS、对象存储、Hive、Kafka 或数据库，数据格式会直接影响性能。