

Spark SQL

DataFrame、数据源、Join、Hive 与 Spark UI

来源：极客时间《零基础入门 Spark》。本文为学习笔记和工程化复盘，不包含课程逐字稿。

DataFrame 与 SQL

- 1 DataFrame 是带 Schema 的分布式表，比 RDD 更利于优化器理解和改写。
- 2 Spark SQL 让批处理逻辑可以用 SQL 或 DataFrame API 表达。
- 3 Catalyst 优化器能分析逻辑计划并生成更优执行计划。

数据源与格式

- 1 CSV/JSON 易读但解析成本高，Parquet/ORC 更适合分析场景。
- 2 Hive 表适合数仓集成，JDBC 适合连接外部数据库但要注意并发压力。
- 3 尽量使用内置函数而不是 UDF，因为内置函数更容易被优化。

Join 与优化

- 1 小表适合 Broadcast Hash Join，大表 Join 常见 Sort Merge Join。
- 2 Join 前先过滤和裁剪列，可以显著减少 Shuffle 数据量。
- 3 倾斜 Key 要单独处理，避免少数 Task 拖慢整个 Stage。

Spark UI

- 1 排查顺序建议从 Applications、Jobs、Stages、Tasks、SQL、Executors 逐层下钻。
- 2 重点看 Stage 耗时、Shuffle Read/Write、长尾 Task、GC、失败重试和物理计划。
- 3 Spark UI 能把调优从猜测变成证据驱动。