

Spark MLlib

特征工程、模型训练与 Pipeline

来源：极客时间《零基础入门 Spark》。本文为学习笔记和工程化复盘，不包含课程逐字稿。

MLlib 定位

- 1 MLlib 适合在大规模数据上做特征处理、模型训练和批量预测。
- 2 房价预测是监督学习入口，可以串起样本、特征、标签、训练集、测试集和评估指标。
- 3 Spark MLlib 的工程价值在于把机器学习流程分布式化和标准化。

特征工程

- 1 常见处理包括缺失值填充、类别编码、文本特征、数值标准化、特征选择和向量化。
- 2 特征工程决定模型上限，也决定训练和预测流程是否稳定。
- 3 能用内置 Transformer 就优先用内置 Transformer，减少 UDF 带来的优化障碍。

模型训练

- 1 回归预测连续值，分类预测离散类别，聚类做无监督分组。
- 2 协同过滤适合推荐，频繁项集适合发现共现模式。
- 3 训练时要关注数据泄漏、样本偏差、特征稳定性和评估指标。

Pipeline

- 1 Pipeline 把特征处理、模型训练、预测和评估串成标准流程。
- 2 Transformer 做转换，Estimator 做训练，Model 表示训练后的模型。
- 3 训练流程和预测流程必须保持一致，否则线上效果会偏离离线评估。