

Structured Streaming

微批、窗口、水位线、流关联与 Kafka

来源：极客时间《零基础入门 Spark》。本文为学习笔记和工程化复盘，不包含课程逐字稿。

核心直觉

- 1 Structured Streaming 把流看成持续追加的数据表，对表的查询持续产生结果。
- 2 流式 Word Count 是理解无界数据处理的最小案例。
- 3 流处理关注的不只是计算结果，还包括延迟、状态、容错和输出语义。

微批与连续处理

- 1 微批模式把流数据切成小批次处理，语义成熟，适合多数秒级或分钟级场景。
- 2 连续处理追求更低延迟，但适用范围和约束更多。
- 3 选择模式要看业务延迟要求、状态操作和精确一次需求。

Window 与 Watermark

- 1 窗口把无界流切成可计算片段，Watermark 处理迟到数据。
- 2 滚动窗口固定且不重叠，滑动窗口按步长滑动，会话窗口按事件间隔切分。
- 3 Watermark 在准确性、延迟和状态大小之间做权衡。

关联与 Kafka

- 1 流批关联适合用静态维表补充事件，流流关联需要时间约束和状态清理。
- 2 Kafka 常作为流计算入口，要管理 offset、反序列化、checkpoint 和下游幂等。
- 3 生产环境要同时观察吞吐、延迟、状态大小和失败恢复。