

生产化与复习清单

从能跑到可诊断、可稳定、可复用

来源：极客时间《零基础入门 Spark》。本文为学习笔记和工程化复盘，不包含课程逐字稿。

作业设计清单

- 1 明确数据源、数据格式、分区策略、业务逻辑、输出路径和下游消费者。
- 2 判断每个算子是否触发 Shuffle，是否改变分区和数据分布。
- 3 对重复使用的数据选择合适缓存策略，并评估内存成本。

性能排查清单

- 1 先看慢在哪个 Stage，再看 Shuffle、输入输出、长尾 Task 和 Executor 指标。
- 2 检查是否有数据倾斜、小文件过多、分区不合理、内存不足或 GC 过高。
- 3 调参要有观测依据，改一次配置记录一次效果。

稳定性清单

- 1 关注 Driver/Executor 内存、Executor 核数、实例数、动态资源分配和失败重试。
- 2 外部数据源要考虑限流、权限、格式兼容和写入幂等。
- 3 Streaming 作业要特别关注 checkpoint、offset、迟到数据和状态清理。

复习问题

- 1 为什么 Spark 要延迟计算？Stage 为什么会被 Shuffle 切开？
- 2 Broadcast Join 和 Sort Merge Join 分别适合什么场景？
- 3 Structured Streaming 的 Watermark 牺牲了什么，换来了什么？